

## 第 1 节: 概率空间简介

Lecturer: 尹一通

Scribes: 张桃玮


## §1 概率空间

**1.1. 定义的由来.** 随机试验是概率论的基本概念, 试验的结果虽说事先不能准确地预言, 但具有如下三个特性:

1. 可以在相同的条件下重复进行;
2. 每次试验的结果不止一个, 但预先知道试验的所有可能的结果;
3. 每次试验前不能确定哪个结果会出现.

这就使得我们把一次试验中**所有可能出现的结果** (possible outcomes) 的集合放在一起考虑. 构成**样本空间 (sample space)**, 一般用  $\Omega$  表示. 对于样本空间的每一个元素  $\omega \in \Omega$ , 称为**样本 (sample)** (或**基本事件 (elementary event)**). 下文所讨论的**事件 (event)** 一般认为是  $\Omega$  的一个子集.

**例子 1.1.** 下图展示了投掷两枚骰子的所有可能结果. 如果我们认为事件  $A :=$  第一枚是 6, 第二枚是 1, 可以看到这是样本空间的一个子集. 事件  $B$  和  $C$  表示什么? 我们会认为“一小格”代表的概率是  $1/36$ ?



实际上, 我们不假思索地认为一小格就是  $1/36$ , 是因为我们认为这 36 种情况是等可能发生的. 因此将某一个小格子 (事件) 映射成了一个实数. 假设这些小格子不是等可能出现的, 我们当然可以把这些小格子映成互不相同的实数. 但是这样的映射  $p: \Omega \rightarrow [0, 1]$  要满足:

- $\sum_{\omega \in \Omega} p(\omega) = 1$ . 我们希望所有的事件发生的概率加起来等于 1.

有了这样对基本元素的映射, 我们就可以定义一个事件  $A \subseteq \Omega$  的概率, 定义作  $\Pr(A) := \sum_{\omega \in A} p(\omega)$ , 称为**事件的概率 (Probability of event)**. 这也引出下一个问题: 到底什么样的集合簇, 才可以被称为**事件构成的集合**?

对于一个有限 (或者可数) 的样本空间  $\Omega$  而言, 我们可以写出样本空间上所有可能的事件:  $2^\Omega$ . 但是, 这个要求能不能放松些? 通过我们以前的知识, 我们发现:

- $\emptyset$  和  $\Omega$  一定要在事件的集合里面. 它们是基础.
- 如果  $A$  在事件的集合中, 其补集  $A^c$  也要在. 不然我们就没有办法很方便地对一个事件取反.
- 如果有可数多个集合  $A_1, A_2, \dots$  在事件集合里面, 那么  $\bigcup_i A_i$  和  $\bigcap_i A_i$  也要在事件的集合里面. 这是为了我们方便地做并集和交集运算.

可以看到, 我们这里定义这样的规则 (2), (3), 完全是基于我们希望我们定义出来的这簇集合的元素在交、并、补这些运算下面**封闭**. 也就是事件集合中拿出任意可数多个元素进行上述集合的运算, 得到的结果一定还在这定义的事件集合里面. 这样我们定义的概率映射  $p$  才有意义.

于是经过上述探讨, 得到下面的概率空间的定义:

**定义 1.1.** 设  $\Omega$  是一个样本空间 (或任意一个集合),  $\Sigma$  是  $\Omega$  的某些子集组成的集合族. 如果满足:

- (1)  $\Omega \in \Sigma$ ;
- (2) 若  $A \in \Sigma$ , 则  $A^c = \Omega \setminus A \in \Sigma$ ;
- (3) 若  $A_n \in \Sigma, n = 1, 2, \dots$ , 则  $\bigcup_{n=1}^{\infty} A_n \in \Sigma$ ;

则称  $\Sigma$  为  $\sigma$  代数 ( $\sigma$ -algebra).  $(\Omega, \Sigma)$  称为可测空间 (measurable space),  $\Sigma$  中的元素称为事件 (events).

这里没有定义交集的原因是, 交集可以通过并集取反得到. 这定义是一个最精简的版本.

**例子 1.2.** 如果研究掷一次硬币的结果, 可用如下  $\Omega$  表示样本空间:

$$\Omega = \{H, T\}$$

如果研究掷两次硬币的结果, 可用如下  $\Omega$  表示样本空间:

$$\Omega = \{\{H, H\}, \{H, T\}, \{T, H\}, \{T, T\}\}$$

如果研究掷一次六面骰子出现 2 或 3 的概率, 可用如下可测空间严格描述:

$$\Omega = \{1, 2, 3, 4, 5, 6\}, F = \{\emptyset, \Omega, \{2, 3\}, \{1, 4, 5, 6\}\}$$

如果研究掷一次六面骰子出现 2 和 3 的概率, 可用如下可测空间严格描述

$$\begin{aligned} \Omega &= \{1, 2, 3, 4, 5, 6\} \\ F &= \{\emptyset, \Omega, \{2\}, \{3\}, \{2, 3\}, \{1, 2, 4, 5, 6\}, \{1, 3, 4, 5, 6\}, \{1, 4, 5, 6\}\} \end{aligned}$$

**定义 1.2.** 设  $(\Omega, \Sigma)$  是可测空间,  $\Pr$  是一个从事件  $\Sigma$  的集合到实数集合的映射 ( $\Pr : \Sigma \rightarrow [0, 1]$ ), 满足

- (1) (归一化)  $\Pr(\Omega) = 1$ ;
- (2) ( $\sigma$ -可加性) 对两两互不相容事件  $A_1, A_2, \dots$ , (即当  $i \neq j$  时,  $A_i \cap A_j = \emptyset$ ) 有

$$\Pr\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} \Pr(A_i)$$

则称  $\Pr$  是  $(\Omega, \Sigma)$  上的**概率测度 (probability measure)**, 三元组  $(\Omega, \Sigma, P)$  称为**概率空间**,  $\Sigma$  中的元素称为事件,  $P(A)$  称为事件  $A$  的概率.

一经建立上述的公理体系 (定义), 我们任何常见的对于概率的想象都可以被验证.

**例子 1.3.** 下面的内容是在中学 “不假思索” 就用的. 我们现在诉诸公理, 证明他们.

- $\Pr(A^c) = 1 - \Pr(A)$ . 这是因为考虑  $A$  和它的补  $A^c$  没有交集, 且组成了全空间, 根据  $\Pr(\Omega) = 1$  以及  $\sigma$ -可加性可知.
- $\Pr(\emptyset) = 0$ . 考虑反证法说明: 因为  $\Pr(A) > 0 \implies A \neq \emptyset$  这样的方法被称为**概率方法 (the probabilistic method)**
- $\Pr(A \setminus B) = \Pr(A) - \Pr(A \cap B)$  可以借鉴问题 1 的思路.
- $A \subseteq B \implies \Pr(A) \leq \Pr(B)$ . 直观来看, 由于  $\Pr$  的值域是  $[0, 1]$ , 点越多, 概率至少不应该变小.
- $\Pr(A \cup B) = \Pr(A) + \Pr(B) - \Pr(A \cap B)$ . 这是容斥原理的一个简单的形式.

**1.2. 几个重要的不等式.** 下面我们介绍几个重要的不等式和一些重要的思想.

#### a) 并的上界 (union bound)

**命题 1.1.** 对于事件  $A_1, A_2, \dots, A_n$ ,

$$\Pr\left(\bigcup_{i=1}^n A_i\right) \leq \sum_{i=1}^n \Pr(A_i)$$

这可以通过上述例子中  $\Pr(A \cup B) = \Pr(A) + \Pr(B) - \Pr(A \cap B)$  得到证明, 并且可以知道等号取得的条件是  $A_i$  两两没有交集.

**b) 容斥原理 (principle of inclusion-exclusion, PIE)** 继续推广  $\Pr(A \cup B) = \Pr(A) + \Pr(B) - \Pr(A \cap B)$ , 当有三个集合的时候, 要算它们的并集就可以转换为它们的交集. 我们接下来先说明一般的容斥原理.

若  $S$  是一个集合, 记  $|S|$  表示集合  $S$  中元素的个数, 对于两个集合而言, 有  $|A \cup B| = |A| + |B| - |A \cap B|$ . 如果是三个集合, 可以写作

$$\begin{aligned} |A \cup B \cup C| = & |A| + |B| + |C| \\ & - |A \cap B| - |A \cap C| - |B \cap C| \\ & + |A \cap B \cap C| \end{aligned}$$

其特点如下:

1. 这是一个把求集合并集化为交集之组合的变换.
2. 如果我们将参与并集那些集合 (如  $A, B, C$ ) 当做一个大集合  $K$ , 其会生成  $K$  的所有子集, 这每个子集的元素 (也是集合) 交起来, 便得到了构成等式右端的基本组件.
3. 如果这个子集的大小为奇数, 前面的符号为正; 反之就是负.

根据我们上面的观察, 实际上我们就可以得到一般的容斥原理:

**定理 1.2** (容斥原理). 假设是  $A_1, A_2, \dots, A_n$  是  $n$  个集合, 那么有

$$\begin{aligned} \left| \bigcup_{i=1}^n A_i \right| &= \sum_{i=1}^n |A_i| - \sum_{i < j} |A_i \cap A_j| + \sum_{i < j < k} |A_i \cap A_j \cap A_k| - \dots \\ &= \sum_{\substack{s \subseteq \{1, 2, \dots, n\} \\ S \neq \emptyset}} (-1)^{|S|-1} \left| \bigcap_{i \in S} A_i \right| \end{aligned}$$

我们来证明这个定理. 最无脑 (但不一定总是可以这样做) 的方法当然是可以使用数学归纳法了. 但是我们今天换一种方法.

*Proof.* 我们的目标是计数的时候每个元素都被算过, 且只被算过一次. 假设  $A_1, \dots, A_n \subset X$ , 对于每一个  $A_i$ , 我们定义一个指示函数. 这个指示函数写作

$$f_i(x) := \begin{cases} 1 & x \in A_i \\ 0 & x \notin A_i \end{cases}$$

我们考虑

$$F(x) = \prod_{1 \leq i \leq n} (1 - f_i(x)).$$

这个函数是集合  $\cup_{1 \leq i \leq n} A_i$  的补的指示函数. 也就是说,  $F(x) = 1 \iff x$  不在任何一个  $A_i$  集合中. 于是,

$$\sum_{x \in X} F(x) = |X \setminus \cup_{1 \leq i \leq n} A_i|.$$

现在我们用另一种视角看  $F(x)$ . 通过把对应的指示函数展开, 可以得到  $2^n$  个元素, 就是

$$F(x) = \prod_{1 \leq i \leq n} (1 - f_i(x)) = \sum_{I \subset [n]} (-1)^{|I|} \prod_{i \in I} f_i(x).$$

实际上,  $\prod_{i \in I} f_i(x)$  就是  $\cap_{i \in I} A_i$  的特征函数, 因此得到

$$\sum_{x \in X} F(x) = \sum_{I \subset [n]} (-1)^{|I|} \sum_{x \in X} \prod_{i \in I} f_i(x) = \sum_{I \subset [n]} (-1)^{|I|} |\cap_{i \in I} A_i|$$

这样一来, 我们就得到了对应的大小信息

$$|X \setminus \cup_{1 \leq i \leq n} A_i| = |X| - |\cup_{1 \leq i \leq n} A_i| = \sum_{I \subset [n]} (-1)^{|I|} |\cap_{i \in I} A_i|$$

于是我们就证明了这个定理. □

实际上, 事件只是特殊的集合, 而概率函数 (Pr) 和个数函数 ( $|\cdot|$ ) 有类似的性质, 因此固然有

对于事件  $A_1, A_2, \dots, A_n \in \Sigma$ , 有

$$\begin{aligned} \Pr\left(\bigcup_{i=1}^n A_i\right) &= \sum_{i=1}^n \Pr(A_i) - \sum_{i<j} \Pr(A_i \cap A_j) + \sum_{i<j<k} \Pr(A_i \cap A_j \cap A_k) - \dots \\ &= \sum_{\substack{S \subseteq \{1,2,\dots,n\} \\ S \neq \emptyset}} (-1)^{|S|-1} \Pr\left(\bigcap_{i \in S} A_i\right) \end{aligned}$$

**例子 1.4 (错排问题).** 取数列  $a = [1, 2, 3, \dots, n]$ , 将它随机打乱. 请问  $a_i \neq i$  的情况有多少?

对计数任务做合理的划分. 有时候从反面考虑会有些帮助. 我们考虑计算“存在  $a_i = i$  的情况的个数”. 定义  $A_i$  表示  $a_i = i$  的可能性. 并且我们发现  $\Pr(\bigcap_{i \in S} A_i) = \frac{(n-|S|)!}{n!}$  这个式子比较好算, 我们的任务成功了一大半. 然后应用容斥原理的表达:

$$\Pr\left(\bigcup_{i=1}^n A_i\right) = \sum_{k=1}^n \sum_{\substack{S \subseteq \{1,2,\dots,n\} \\ |S|=k}} (-1)^{k-1} \Pr\left(\bigcap_{i \in S} A_i\right) = \sum_{k=1}^n \binom{n}{k} (-1)^{k-1} \frac{(n-k)!}{n!}$$

由于我们的问题是回答的反面, 自然用 1 减, 得到

$$\Pr\left(\bigcap_{i=1}^n A_i^c\right) = 1 - \Pr\left(\bigcup_{i=1}^n A_i\right) = 1 + \sum_{k=1}^n \frac{(-1)^k}{k!} = \sum_{k=0}^n \frac{(-1)^k}{k!}$$

当  $n$  很大的时候, 它接近  $1/e$ .

**1.3. 概率测度的连续性.** 就像我们在  $\mathbb{R}, \mathbb{R}^2$  上面定义了距离的度量, 然后由此导出了邻域的定义. 一旦定义了邻域, 就可以定义映射极限的概念.

**定理 1.3 (概率测度是连续的).** 如果  $A_1 \subseteq A_2 \subseteq A_3 \subseteq \dots$  是一系列事件, 我们定义这一簇集合的极限为  $A$ , 表示

$$A := \bigcup_{i=1}^{\infty} A_i = \lim_{i \rightarrow \infty} A_i.$$

那么有  $\Pr(A) = \lim_{i \rightarrow \infty} \Pr(A_i)$

这条定理说明了: 只要搞明白这一簇集合最终的极限是什么, 我们就能够得到与之对应的  $\Pr(A)$  是多少. 不必再去考虑每一个集合  $A_i$  单独做映射得到  $\Pr(A_i)$  并求极限.

*Proof.* 关键是使用不相交集的可加性. 如果我们把最终的极限  $A$  写作若干个不交和  $A = A_1 \uplus (A_2 \setminus A_1) \uplus (A_3 \setminus A_2) \uplus \dots$ , 那么

$$\begin{aligned} \Pr(A) &= \Pr(A_1) + \sum_{i=1}^{\infty} \Pr(A_{i+1} \setminus A_i) \\ &= \Pr(A_1) + \lim_{n \rightarrow \infty} \sum_{i=1}^{n-1} [\Pr(A_{i+1}) - \Pr(A_i)] \\ &= \lim_{n \rightarrow \infty} \Pr(A_n) \end{aligned}$$

□

同样的, 如果我们有不断变小的一系列集合, 也有同样的定理, 即: 如果  $B$  是事件集合  $B_1, B_2, \dots$ , 满足  $B_1 \supseteq B_2 \supseteq B_3 \supseteq \dots$  的集合的极限 (定义作  $B = \bigcap_{i=1}^{\infty} B_i = \lim_{i \rightarrow \infty} B_i$ ), 那么有  $\Pr(B) = \lim_{i \rightarrow \infty} \Pr(B_i)$ . 实际上我们可以考虑上述各个事件的补, 也就是考虑  $B_1^c \subseteq B_2^c \subseteq B_3^c \subseteq \dots$  – 就转化到了上述定理的内容了.

有了上述的铺垫, 我们可以看一看**零事件 (null event)**.

**定义 1.3 (零事件).** 如果一个事件  $A \in \Sigma$ , 满足  $\Pr(A) = 0$ , 那么就称它为零事件.

注意零事件和不可能事件的区别. 零事件不一定是不可能事件. 即: 概率为 0 不一定不会发生.

与之对应, 概率为 1 也不一定会发生. 像概率为 1 事件我们叫做几乎必然事件.


**定义 1.4 (几乎必然 (almost surely, a.s.)).** 如果一个事件  $A \in \Sigma$ , 满足  $\Pr(A) = 1$ , 那么就称它为几乎必然事件.

## §2 条件概率

考虑“在事件  $B$  发生的条件下,  $A$  发生的概率是  $p$ ”. 在中学学过条件概率公式

$$p = \frac{|A \cap B|}{|B|} = \frac{|A \cap B|/|\Omega|}{|B|/|\Omega|} = \frac{\Pr(A \cap B)}{\Pr(B)}$$

这是因为考虑直观的意义, 可以把  $A \cup B$  和  $B$  在全空间的意义下分别表示.



用集合的术语来说, 这就相当于在原有的集合上面做了一个限制. 我们现在为它下一个定义, 看一看概率空间的基础上, 如何定义条件概率.

### 2.1. 基本定义.

**定义 2.1.** 如果  $A$  是一个事件,  $B$  是一个  $\Pr(B) > 0$  的事件, 那么  $A$  在  $B$  发生的条件下发生的**条件概率 (conditional probability)** 被定义作

$$\Pr(A | B) := \frac{\Pr(A \cap B)}{\Pr(B)}$$

这样的定义是合理的. 只要我们

- 把样本空间看做  $B$ ;
- $\Sigma^B := \{A \cap B : A \in \Sigma\}$  满足  $\sigma$ -代数的条件;
- $\Pr(\cdot | B)$  满足概率的公理.

那么, 由  $(B, \Sigma^B, \Pr)$  也构成一个概率空间.

**例子 2.1.** 假设你有一个以概率为  $p$  出现正面 (H) 的硬币, 但是不知道  $p$  是多少. 你应该如何用这个硬币生成均匀的硬币投掷?

答案: 只要我们不断地投掷, 当连续两次投掷结果是 HT 的情况下, 就等效地认为扔出了正面; 连续两次投掷出现 TH, 就认为扔出了反面.

这是因为

$$\Pr(\text{HT} \mid \{\text{HT}, \text{TH}\}) = \Pr(\text{TH} \mid \{\text{HT}, \text{TH}\}) = \frac{p(1-p)}{2p(1-p)} = \frac{1}{2}$$

**例子 2.2.** 已知两个孩子, 至少一个是女孩. 那么两个孩子都是女孩的概率是多少?(假设男孩和女孩出现等概率).

假设在空间有  $\Omega = \{\text{BB}, \text{BG}, \text{GB}, \text{GG}\}$ , 每种情况发生的可能性相同. 那么

$$\begin{aligned} \Pr(\{\text{GG}\} \mid \{\text{BG}, \text{GB}, \text{GG}\}) &= \frac{\Pr(\{\text{GG}\})}{\Pr(\{\text{BG}, \text{GB}, \text{GG}\})} \\ &= \frac{1/4}{3/4} = \frac{1}{3} \end{aligned}$$

## 2.2. 条件概率的性质.

**a) 链式法则** 链式法则 (Chain rule) 描述了我们为什么像计数的时候应用乘法原理那样对“分步决策的”两个概率乘起来. 其表述如下:

**定理 2.1** (链式法则). 假设  $A_1, A_2, \dots, A_n$  有正概率, 那么

$$\Pr(A_1 \cap A_2 \cap A_3 \cap \dots \cap A_n) = \Pr(A_1) \Pr(A_2 \mid A_1) \Pr(A_3 \mid A_1 \cap A_2) \cdots \Pr(A_n \mid A_1 \cap A_2 \cap \dots \cap A_{n-1})$$

也就是

$$\Pr\left(\bigcap_{i=1}^n A_i\right) = \prod_{i=1}^n \Pr\left(A_i \mid \bigcap_{j<i} A_j\right)$$

*Proof.* 首先回到定义上面去. 可以使用裂项的方法证明.

$$\Pr\left(\bigcap_{i=1}^n A_i\right) = \frac{\Pr\left(\bigcap_{i=1}^n A_i\right)}{\Pr\left(\bigcap_{i=1}^{n-1} A_i\right)} \cdot \frac{\Pr\left(\bigcap_{i=1}^{n-1} A_i\right)}{\Pr\left(\bigcap_{i=1}^{n-2} A_i\right)} \cdots \frac{\Pr(A_1 \cap A_2)}{\Pr(A_1)} \cdot \Pr(A_1)$$

□

**例子 2.3.** 把  $n$  个球一个一个地随机扔进  $m$  个盒子里面, 请问每个球都扔进了一个空盒子的概率是多少?

答案: 考虑分步进行. 很容易求“对于编号  $j$  的球 ( $j < i$ ) 都扔进了一个空桶的情况下, 编号  $i$  的球扔进了一个空桶的概率”为  $1 - \frac{i-1}{m}$ . 那么根据上述的定理:

概率就是

$$\prod_{i=1}^n \left(1 - \frac{i-1}{m}\right)$$

**2.3. 全概率公式.** 全概率公式说的事情是对于一个复杂的样本空间, 与其在其上面一整个上面求概率, 不如先把样本空间做一个划分, 在划分的小片上面计算概率, 然后把它们加起来.

**定理 2.2** (全概率公式). 令事件  $B_1, B_2, \dots, B_n$  是  $\Omega$  的一个分割, 其中对任何的  $i$ , 都有  $\Pr(B_i) > 0$  那么,

$$\Pr(A) = \sum_{i=1}^n \Pr(A \cap B_i) = \sum_{i=1}^n \Pr(A | B_i) \Pr(B_i)$$

*Proof.* 由于  $A \cap B_1, A \cap B_2, \dots, A \cap B_n$  是互不相交的, 且  $A = \bigcup_{i=1}^n (A \cap B_i)$ . 这就表明  $\Pr(A) = \sum_{i=1}^n \Pr(A \cap B_i)$ .

这同样表明了  $\Pr(A \cap B_i) = \Pr(A | B_i) \Pr(B_i)$ . □

**例子 2.4** (三门问题). 假设你参加一个游戏节目, 有三扇门. 其中一扇门后面有大奖, 另外两扇门后面是什么都没有. 你选择了一扇门 (比如第一个门), 主持人知道每扇门后面是什么. 然后, 他打开了另外一扇门 (比如第三个门), 里面是什么都没有. 然后他问你: “你要换成第二号门吗?” 你应该换门吗?

答案: 应该换. 定义事件  $A$  为我们最后得到了大奖;  $B$  为一开始我们选了含有车的那个门. 那么

$$\Pr(A) = \begin{cases} \Pr(B) = 1/3 & \text{不换门} \\ \Pr(A | B) \Pr(B) + \Pr(A | B^c) \Pr(B^c) = 0 + 1 \times 2/3 = 2/3 & \text{换门} \end{cases}$$

**例子 2.5** (赌徒破产问题). 一赌徒扔一枚均匀硬币. 如果他得到正面, 会得到 1 元; 如果得到反面, 就会输掉 1 元. 他从  $k$  元开始游戏. 在他有的总钱数超过  $k$  的时候 (赢了) 或者小于 0 的时候 (破产, 输了) 停止游戏. 问他最后赢的概率是多少.

答案: 定义事件  $A :=$  赌徒破产输了;  $B :=$  第一次掷硬币的时候得到了正面.

以及让  $\Pr_k$  表示赌徒以  $k$  元开始游戏. 由于输掉一元之后可以重新看做以  $k-1$  元开始, 有如下的递归式:

$$\Pr_k(A) = \frac{1}{2} \Pr_k(A | B) + \frac{1}{2} \Pr_k(A | B^c) = \frac{1}{2} \Pr_{k+1}(A) + \frac{1}{2} \Pr_{k-1}(A)$$

解这个递归式, 就有

$$\Pr_k(A) = \begin{cases} \frac{1}{2} (\Pr_{k+1}(A) + \Pr_{k-1}(A)) = 1 - \frac{k}{n} & \text{if } 0 < k < n \\ 1 & \text{if } k = 0 \\ 0 & \text{if } k = n \end{cases}$$

也就是赌徒最后一定会破产.

下面来看全概率公式的一重要变形. 我们会成它为 Bayes 定理. 这项定理可以帮助把条件概率的条件 “反过来”. 有时候也会称它为 “逆概率公式”.



**定理 2.3 (Bayes 定理 (Bayes Theorem)).** 对于事件  $A, B$  满足  $\Pr(A), \Pr(B) > 0$ , 有

$$\Pr(B | A) = \frac{\Pr(B) \Pr(A | B)}{\Pr(A)}$$

如果  $B_1, B_2, \dots, B_n$  是  $\Omega$  的一个划分,  $\forall i, \Pr(B_i) > 0, \Pr(A) > 0$ , 那么

$$\Pr(B_i | A) = \frac{\Pr(B_i) \Pr(A | B_i)}{\Pr(A)} = \frac{\Pr(B_i) \Pr(A | B_i)}{\Pr(A | B_1) \Pr(B_1) + \dots + \Pr(A | B_n) \Pr(B_n)}$$

这定律可以用全概率公式和链式法则想办法把  $A, B$  互换顺序就可以推出.

**例子 2.6 (假阳性问题).** 一个函数的疾病以 0.001 的概率发生. 但是有 5% 的测验误差.

也就是说, 有病的人  $\begin{cases} \text{测出有病 (+)} 95\% \\ \text{测出没病 (-)} 5\% \end{cases}$ , 没病的人  $\begin{cases} \text{测出没病 (-)} 95\% \\ \text{测出有病 (+)} 5\% \end{cases}$ .

现在问, 如果一个人测出有病的条件下, 他得病的概率是多少?

答案:

$$\begin{aligned} \Pr(\text{有病} | +) &= \frac{\Pr(\text{有病}) \Pr(+ | \text{有病})}{\Pr(+)} = \frac{\Pr(\text{有病}) \Pr(+ | \text{有病})}{\Pr(+ | \text{有病}) \Pr(\text{有病}) + \Pr(+ | \neg \text{有病}) \Pr(\neg \text{有病})} \\ &= \frac{0.001 \times 95\%}{95\% \times 0.001 + 5\% \times 0.999} \approx 1.87\% \end{aligned}$$

实际上, 在不同的条件下, 我们看到的内容会很不一样. Simonson 发现了这样的一个人“悖论”:

**例子 2.7 (Simonson 悖论).** 如下是两个药品的临床试验数据:

	女		男	
	药品 I	药品 II	药品 I	药品 II
成功	200	10	19	1000
失败	1800	190	1	1000

请问哪一个药品更有效?

1. 药品 I 更有效, 因为总体来看 I 的成功率高于 II.
2. 药品 II 更有效, 对于女性和男性分别而言, II 的成功率都要大于 I.

用概率的语言来讲, 就是对于事件  $A, B$  以及  $\Omega$  的一个划分  $C_1, C_2, \dots, C_n$ , 有可能出现:


- 每一个  $C_i$ ,  $B$  的发生对  $A$  有积极影响, 即

$$\Pr(A | B \cap C_i) > \Pr(A | B^c \cap C_i), \forall i$$

- 但是, 总体来看,  $B$  的发生对  $A$  的发生有消极影响. 即

$$\Pr(A | B) < \Pr(A | B^c)$$

一个例子是, 总体来看, 下图表示了学习时长越长, 成绩越低; 但是一门课一门课来看, 总体学习时长越长, 分数越高.



### §3 事件的独立性

**3.1. 基本定义.** 有时候, 有些事件的发生会影响另一个事件发生的概率. 也就是从  $\Pr(A)$  变为  $\Pr(A|B)$ . 如果我们发现  $\Pr(A|B) = \Pr(A)$ , 我们就可以称这两个事件独立. 但是, 这样的定义可能会不能处理  $\Pr(B) = 0$  的情形, 于是更换一个更加方便的定义:

**定义 3.1** (两个事件的独立性). 如果两个事件满足

$$\Pr(A \cap B) = \Pr(A) \Pr(B)$$

我们就称两个事件**独立 (independent)**.

关于独立, 有如下的几个常用的性质.

1° 如果  $\Pr(B) > 0$ ,  $\Pr(A|B) = \Pr(A) \iff \Pr(A \cap B) = \Pr(A) \Pr(B)$ ;

2°  $\Pr(A \cap B) = \Pr(A) \Pr(B) \iff \Pr(A \cap B^c) = \Pr(A) \Pr(B^c)$

受刚才定义的启发, 我们定义一簇事件  $\{A_i | i \in I\}$  互相独立的条件.

**定义 3.2.** 一簇事件  $I = \{A_i | i \in I\}$  成为 (相互) 独立的, 当且仅当对于任何  $I$  的有限子集  $J \subset I$ , 满足

$$\Pr\left(\bigcap_{i \in J} A_i\right) = \prod_{i \in J} \Pr(A_i).$$

如果我们想要说一个事件和其他的一簇事件独立, 则有如下的定义.

**定义 3.3.** 事件  $A$  与另一簇事件  $\{B_1, B_2, \dots, B_k\}$  互相独立, 当且仅当对任意的下标集合  $S \subset \{1, 2, 3, \dots, k\}$  满足

$$\Pr\left(B \mid \bigcap_{i \in S} B_i\right) = \Pr(B).$$

按独立性的定义来判定, 有时候我们与生俱来的直觉可能会起到反作用. 例如, 如下的几种可能的情况都是可能的:

1.  $A_1, A_2, \dots, A_n$  相互独立,  $B_1, B_2, \dots, B_n$  也相互独立. 但是  $\forall 1 \leq i \leq n, A_i$  和  $B_i$  不相互独立.
2.  $\forall 1 \leq i \leq n, A_i$  和  $B_i$  相互独立; 但是  $\forall 1 \leq i < j \leq n, A_i$  和  $A_j, B_i$  和  $B_j$  都不相互独立.

但是我们可以试图把这些事件的依赖关系画成图. 有连边的两个顶点说明他们有某种相关性. 比如我们有事件  $B_1, B_2, \dots, B_n$ , 如果构造一个有向图  $D = (\{1, 2, 3, \dots, n\}, E)$

QUEST: 无向图还是有向图?

如果  $B_i$  与所有  $(i, j) \notin E$  的  $B_j$  这一簇事件  $(\{B_j : (i, j) \notin E\})$  独立, 我们就称这个图为依赖关系的依赖图. 对于互相独立的一组事件, 它的依赖图就是孤零零的一些点, 并没有连边.

依赖关系图并不是唯一的. 我们可以构造出不同的依赖图.

与互相独立相对, 我们也可以定义一簇事件中两两独立.

**定义 3.4 (两两独立 (pairwise independent)).** 对于一簇事件  $\{A_i \mid i \in I\}$ , 我们称它为两两独立, 当且仅当对于不同的下标  $i, j \in I$ , 有

$$\Pr(A_i \cap A_j) = \Pr(A_i) \Pr(A_j)$$

实际上, 互相独立是一个很强的定义. 即: 互相独立的一簇事件一定是两两独立的; 但是两两独立的事件不一定是互相独立的.

最后我们来定义条件概率意义下的独立.

**定义 3.5 (条件独立).** 两个事件  $A, B$  在  $C$  事件下独立 ( $\Pr(C) > 0$ ), 意味着

$$\Pr(A \cap B \mid C) = \Pr(A \mid C) \Pr(B \mid C)$$

这同样也没有偏离我们对独立的刻画: 如果  $\Pr(B \cap C) > 0$ , 那么  $\Pr(A \cap B \mid C) = \Pr(A \mid C) \Pr(B \mid C) \iff \Pr(A \mid B \cap C) = \Pr(A \mid C)$

**3.2. 由 Cartesian product 生成的概率空间.** 在离散数学中学习过两个集合的 Cartesian product: 如果有两个集合  $A, B$ , 那么定义  $A \times B = \{(i, j) : i \in A, j \in B\}$ . 通常会从两次或者多次独立实验序列中构造一个概率空间. 例如考虑离散的概率空间  $(\Omega_1, p_1), (\Omega_2, p_2), \dots, (\Omega_n, p_n)$ , 那么这个大的概率空间  $(\Omega, p)$  可以这样构造:

- 样本空间  $\Omega = \Omega_1 \times \Omega_2 \times \dots \times \Omega_n$
- $\forall \omega = (\omega_1, \dots, \omega_n) \in \Omega$ , 对应的  $p(\omega) = p_1(\omega_1) \cdots p_n(\omega_n)$ .

对于一般的概率空间  $(\Omega_1, \Sigma_1, \Pr_1), \dots, (\Omega_n, \Sigma_n, \Pr_n)$ , 在这些概率空间上面做 Cartesian product, 需要满足:

- $\Sigma$  是 (唯一) 最小的包含  $\Sigma_1 \times \dots \times \Sigma_n$  的  $\sigma$ -代数;
- $\Pr$  扩展为  $\forall A = (A_1, \dots, A_n) \in \Sigma_1 \times \dots \times \Sigma_n, \Pr(A) = \Pr(A_1) \cdots \Pr(A_n)$ .

## 注记

容斥原理的证明来自<https://math.mit.edu/~fox/MAT307-lecture04.pdf>, 像这样使用多项式的性质证明组合结构的内容会在《组合数学》课程上面频繁用到. 蒋炎岩老师也曾经面向中学生提到过容斥原理. 详见视频<https://www.bilibili.com/video/BV1G3411h7f5>.

一个事件和另一簇事件的独立性采用的定义来自<https://cse.buffalo.edu/~hungngo/classes/2011/Spring-694/lectures/lm.pdf>. 这份定义随后说明了依赖图, 并且由它导出了一个比较有趣的定理. 但是上面的定义和 Slides 定义不太一致. 我也不知道应该用哪个更妥当一点.

本节需要特别注意的是: 概率空间以及上面的不等式; 条件概率及其的性质; 事件的独立性的定义. 还要尤其体会在解决问题的时候用到的递归思想.